Non-AFD EP4 基线的 MoE 算子实现

本次观测表明，Non-AFD EP4 的路由专家分支实际使用 CANN MegaMoE 融合算子。

实验设置

模型基线	DeepSeek-V4-Flash W4A8；历史 vLLM v0.26
软件版本	vLLM `d02df748`；Ascend `5cfb1697` + 归档补丁 [1]
执行配置	DP1 / TP4 / EP4，MRv1 / Eager，MBT8192
prefill 采样	prefix cache OFF / CWS ON；17,408 输入 / 1 输出 token，1 次采集

观测结果与解释

CPU 端记录的算子名为 `cann_ops_transformer::npu_mega_moe`，对应的 NPU kernel 名为 `MegaMoe`。四个 rank 中，每个 rank 均记录到 129 次 CPU 调用和 129 次 NPU kernel，二者通过 `async_npu` 事件一一关联。这些关联确认了 MegaMoE 在设备端的实际执行。

该路径与源码条件一致：启用 fused_mc2 且 CANN MegaMoE 组件可用时，选择 MegaMoE 分支 [2]。

融合边界外：路由选择（Router / Top-k）与共享专家（shared-expert）



图 1 路由专家分支的融合范围（功能示意）

证据定位

`rank0.trace.json`：JSON 根数组，索引从 0 起。

`CPU[1223] -> flow[241664]/[241665] -> NPU[137025] (Stream 47)`

`flow ID=1792501197968488973; NPU ts=1792501197968488.973 us`

Trace 保留事件重叠布局及少量外围 flow 告警，所引调用的 CPU-NPU 关联完整。

`SHA256: c7b911cdf42b7199cc62b3c0ce3eb67959aa59b9dbea4f1715850fa6440a2331`

版本与源码依据

[1] afd-benefit-benchmark / environment/versions.json；固定 commit：`3c403869fcadd3c4c7b238f0cd67413bd1ee871b`。

[2] `_apply_cann_mega_moe` 分支：vllm_ascend/ops/fused_moe/moe_comm_method.py:L458-460；CANN 支持判定见 ascend_forward_context.py:L43。
Ascend 固定 commit：`5cfb1697cf570b3bae2e30f9cc76d9e4e8bb5f46`。