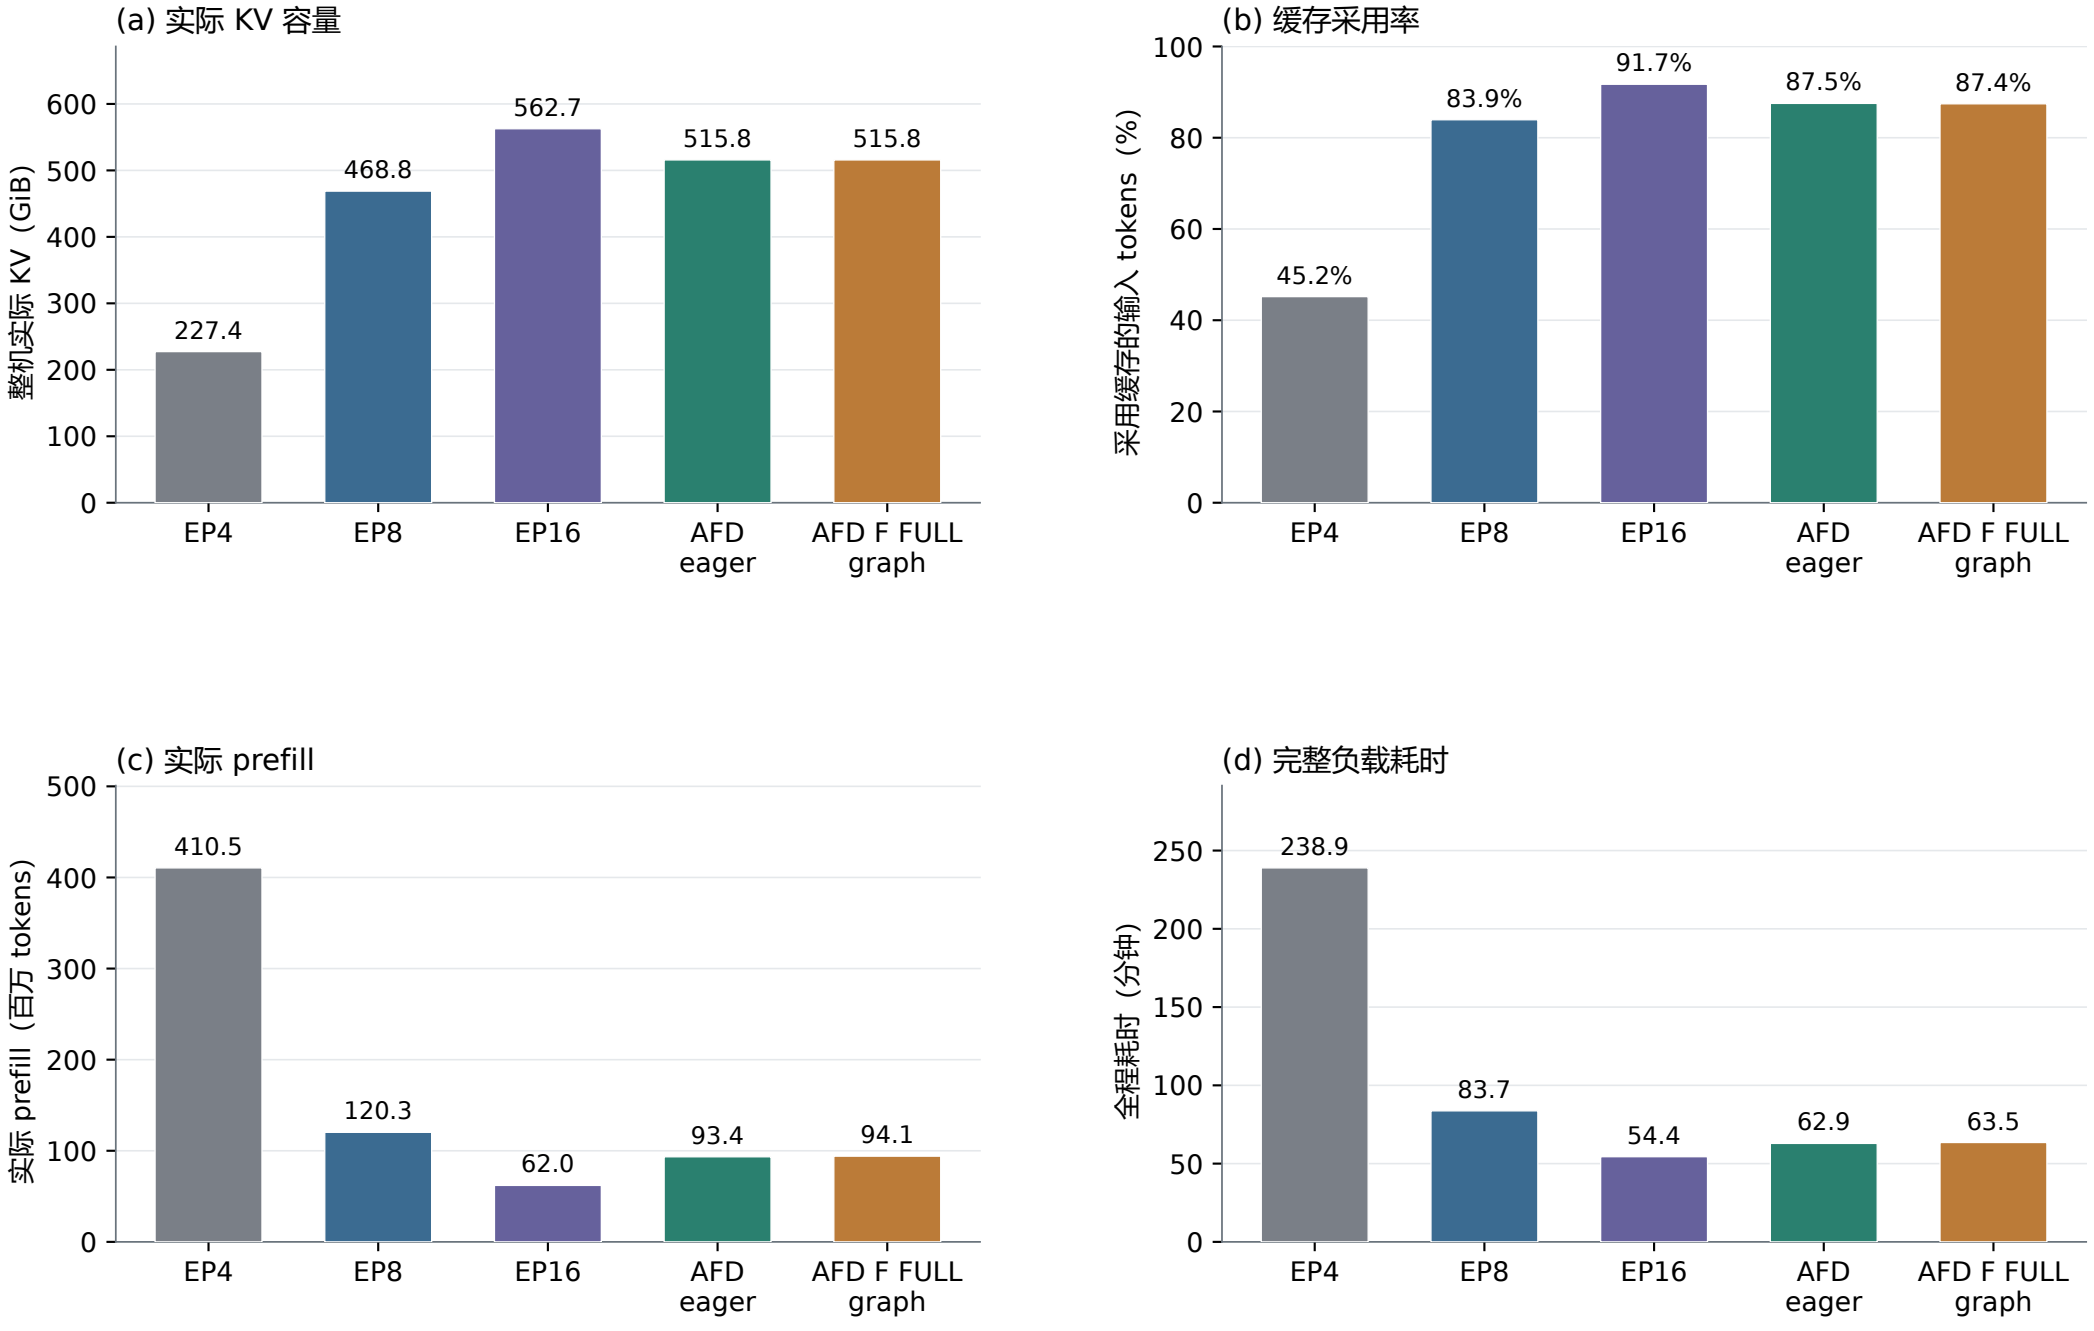
(a) 实际 KV 容量
整机实际 KV（GiB）
0
100
200
300
400
500
600
227.4
468.8
562.7
515.8
515.8
EP4
EP8
EP16
AFD eager
AFD F FULL graph
(b) 缓存采用率
采用缓存的输入 tokens（%）
0
20
40
60
80
100
45.2%
83.9%
91.7%
87.5%
87.4%
EP4
EP8
EP16
AFD eager
AFD F FULL graph
(c) 实际 prefill
实际 prefill（百万 tokens）
0
100
200
300
400
500
410.5
120.3
62.0
93.4
94.1
EP4
EP8
EP16
AFD eager
AFD F FULL graph
(d) 完整负载耗时
全程耗时（分钟）
0
50
100
150
200
250
238.9
83.7
54.4
62.9
63.5
EP4
EP8
EP16
AFD eager
AFD F FULL graph