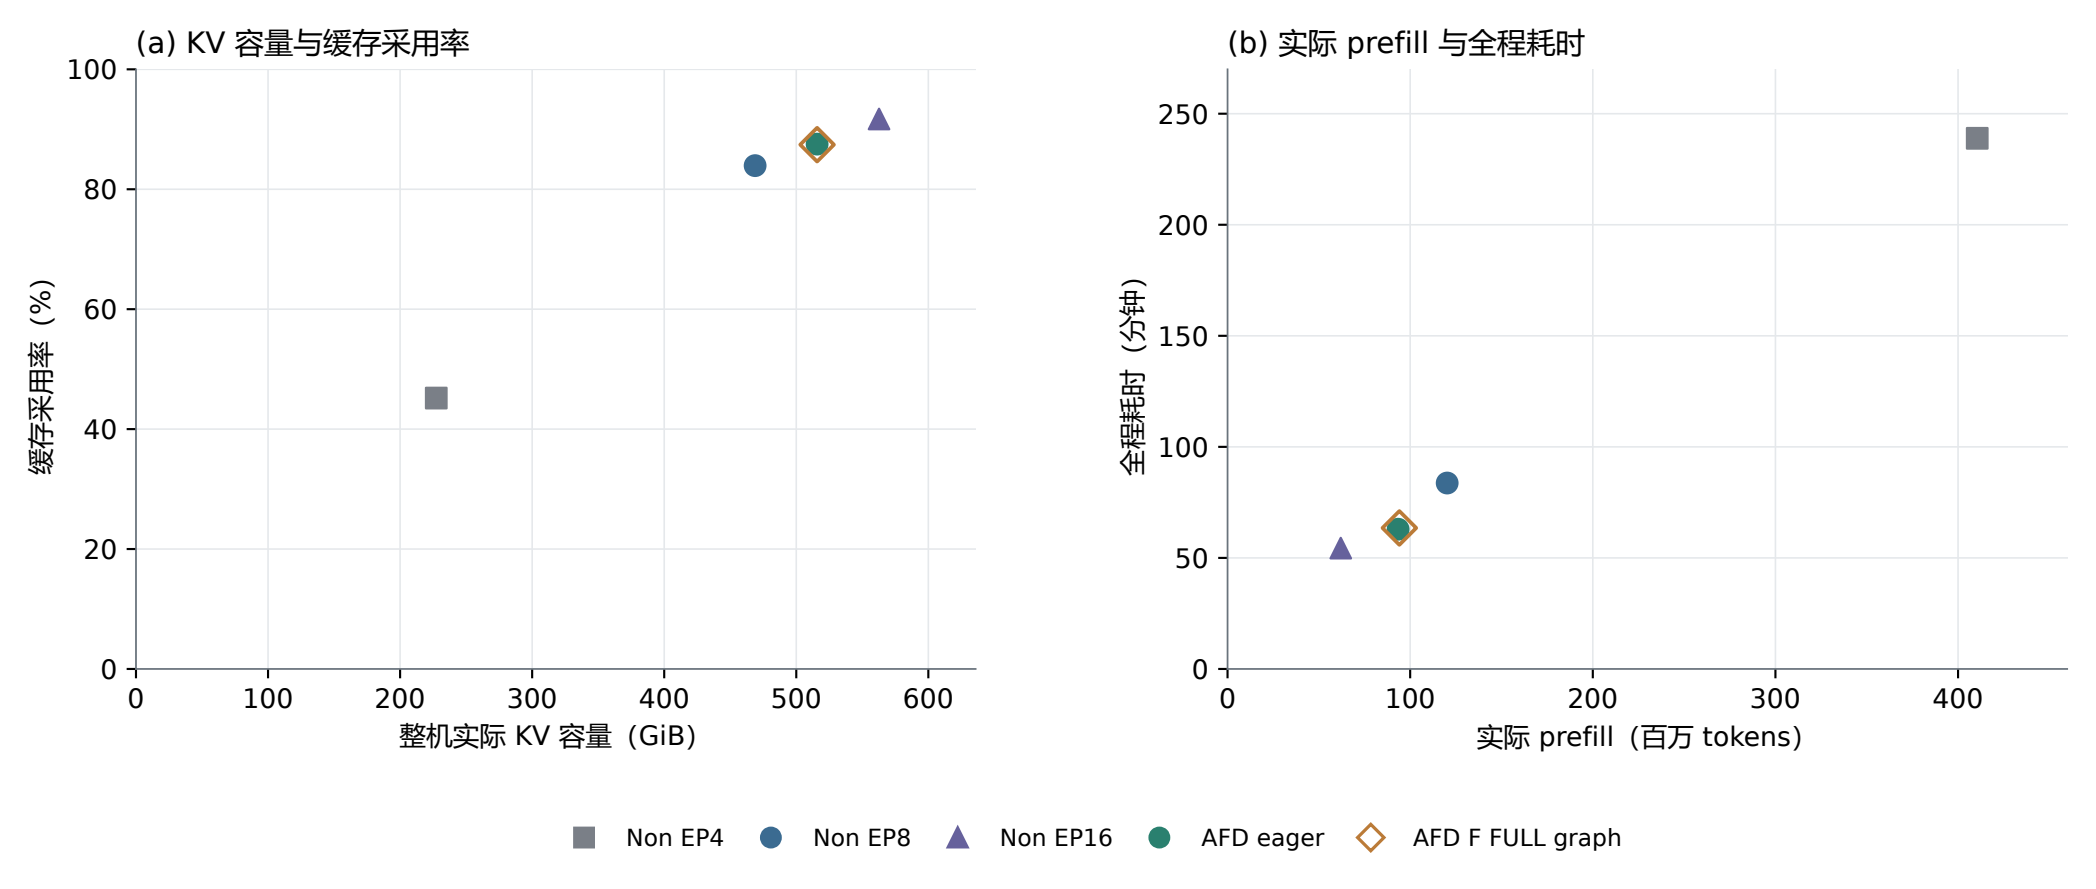
(a) KV 容量与缓存采用率
缓存采用率（%）
整机实际 KV 容量（GiB）
0
20
40
60
80
100
0
100
200
300
400
500
600
(b) 实际 prefill 与全程耗时
全程耗时（分钟）
实际 prefill（百万 tokens）
0
50
100
150
200
250
0
100
200
300
400
Non EP4
Non EP8
Non EP16
AFD eager
AFD F FULL graph