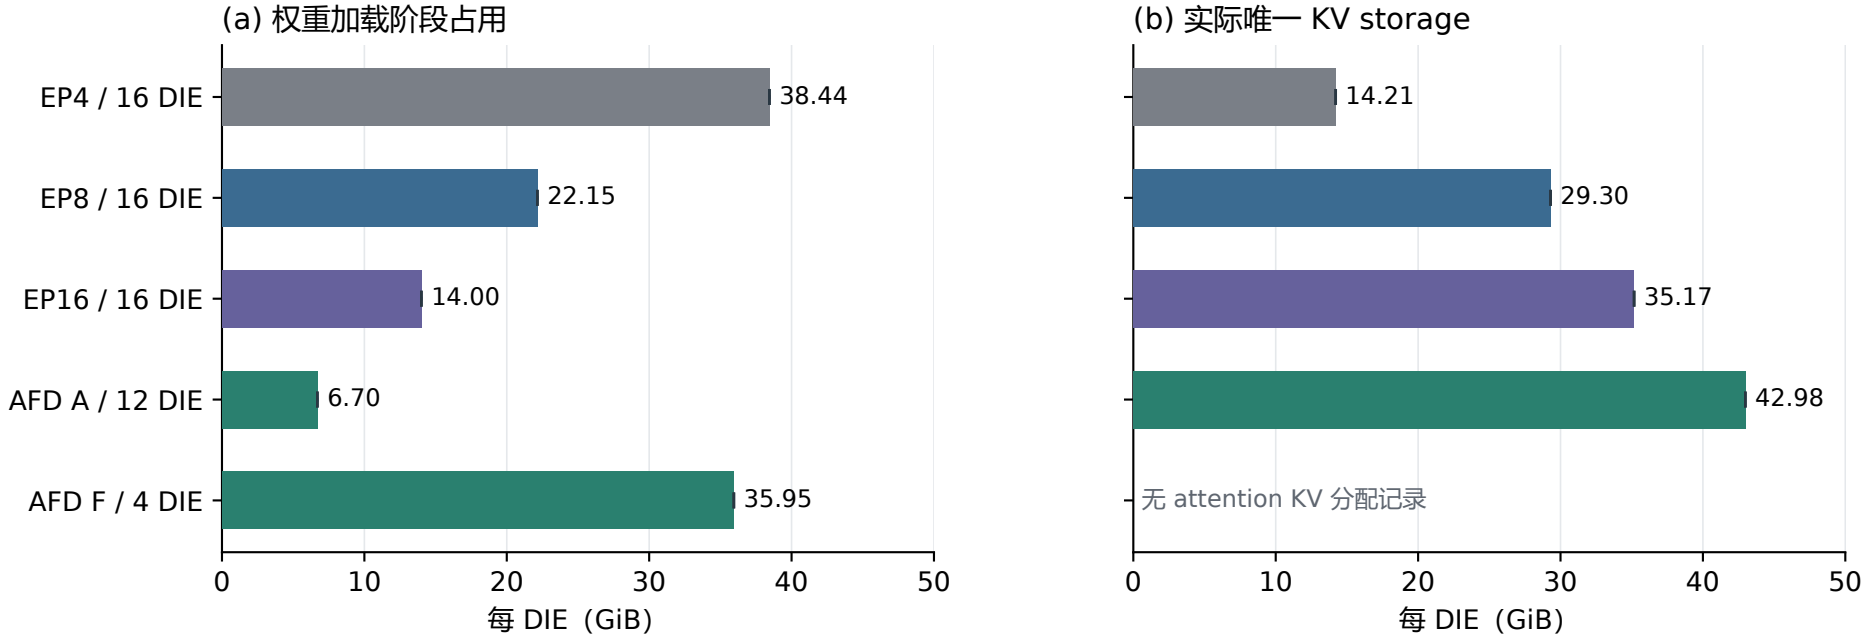
(a) 权重加载阶段占用
EP4 / 16 DIE
EP8 / 16 DIE
EP16 / 16 DIE
AFD A / 12 DIE
AFD F / 4 DIE
38.44
22.15
14.00
6.70
35.95
0
10
20
30
40
50
每 DIE（GiB）
(b) 实际唯一 KV storage
14.21
29.30
35.17
42.98
无 attention KV 分配记录
0
10
20
30
40
50
每 DIE（GiB）