Prefix-on 收益场景：128 完整会话、C12 四组实验

实验与报告日期：2026 年 10 月 14 日。

在相同 16 DIE、prefix caching 开启的本次负载下，AFD eager 完成 128 个完整会话耗时 940.08 秒，比 EP4、EP8、EP16 分别少 51.77%、6.54%、21.65%。 四组各一次完整回放，合计 14,900 条请求全部成功。本次找到了符合目标的实测候选：AFD 对 EP4、EP8 有收益，对 EP16 也没有出现耗时劣势。

AFD、EP8、EP16 的 **3,725 条请求逐条缓存采用完全相同**，实际 prefill 均为 19,710,102 tokens。AFD 对这两组的优势是在等量实际 prefill 下观察到的系统完成效率差异。EP4 实际 prefill 为 50,688,150 tokens，比 AFD 多 30,978,048 tokens，缓存工作量也存在差异。四组均零抢占、零抢占重算；单次结果不代表稳定收益或普遍优势。

设计与可比条件

研究目标是在 prefix-on 的条件下，寻找 AFD 优于 EP4、EP8 且不慢于 EP16 的实际工作负载。先用 CPU 缓存模拟筛选候选，再冻结 **源顺序前 128 个完整会话 / 全局 HTTP C12** 进入实测。模拟不预测端到端时长，是否获益以四组设备实测为准。

四组在**同一物理节点、同一 Pod** 上顺序独占 16 DIE，使用相同 DeepSeek-V4-Flash W4A8 模型、tokenizer、公共 vLLM/Ascend 及已验证的 Compressor host 修复。实际正式顺序为 EP8 → AFD eager → EP16 → EP4；每组独立启动/profile、冷缓存 reset，并保存各域原生计数和端点 metrics 基线。每组正式回放一次，没有请求重试或结果拼接，没有 profiler。

部署	16 DIE 拓扑	KV 缓存域	每域单步 token 预算 MBT	执行模式
Non EP4	4×DP1/TP4/EP4	4	8,192	eager
Non EP8	2×DP2/TP4/EP8	4	8,192	eager
Non EP16	1×DP4/TP4/EP16	4	8,192	eager
AFD eager	12A+4F；A DP3/TP4，F DP4/TP1/EP4	3	32,768	A/F eager

共同参数为 max model length 262,144、block size 32、显存利用率目标 0.9、checkpoint ratio 0.25、prefix caching 和 chunked prefill 开启、每个缓存域最多处理 8 条序列、异步调度开启、OMP4 及原绑核。AFD 保留 CAM 异步通信、两份 token 微批次、F layered GMM=1、共享专家在 A 侧；FlashComm、MC2 和通信缓冲沿用各自既定配置。**这是既定部署的系统比较**：MBT、缓存域数、专家与通信布局随部署变化，没有把这些配置强制为相同，也没有对每组重新调到最优。

软件固定为 vLLM `d02df748bf9efd99022f1a062597dc3cb3808485`；Ascend base `52411eb0dec8b3b3d05e8bdf5a9adb7698fb80c5` 加 PR #4 head `5cfb1697cf570b3bae2e30f9cc76d9e4e8bb5f46` 及已记录补丁；AFD `release/v0.26.0rc2` 的 `cda849a5e0a54576472096c0073f00c7095726f5` 与匹配 CAM/native。各组检查了 16 个 worker 的实际环境、加载算子与修复 host，以及原生异步调度类 `CompressorCheckpointAsyncScheduler`。相对各自已成功 C12 基线，规范化后的服务 argv 无变化，模型与性能参数未调整；允许变化仅为记录位置和恢复后的 Pod/网络身份。实际配置、配置核对、发压前与加载审计保留公开字段。

数据集、会话并行与调度

本轮直接从已发布的 256 会话冻结负载 取源会话 **0–127**，保留每个会话全部轮次和原始请求字节：128 会话、3,725 请求、294,584,470 输入 tokens，每会话 9–75 轮，最大 prompt 216,178 tokens，输出固定 1 token。没有重新分词、截短历史、凑请求数或在实测后按收益挑会话。请求 SHA256 为 `65e10b43838be7bdf1f7459a07d34f1a57b64d05fa75fbf2b94f46efed6e86a4`；128 会话清单与原母集派生方法可复核。

128 个会话进入真实 AgentInfer 依赖图。客户端在**已经就绪的请求**中按预先冻结的优先级准入，全局最多保持 **12 条尚未完成的 HTTP/SSE 请求**；这就是 C12。后续轮次必须等本会话前一轮完成，没有新增轮次屏障或人为等待，本轮生成内容不回填下一轮冻结历史。客户端 C12、完整会话数 128、服务端每域最多 8 条序列，分别约束不同层次。

同一会话固定到一个 KV 缓存域，即保存并复用该会话历史的独立调度/缓存单元。按各会话最大历史长度降序、逐个分配给当前累计负载最小的域，事前生成均衡路由。Non 三组共用同一四域映射，每域 32 会话；AFD 三域分别为 43、42、43 会话。EP8 的域对应实例内 DP rank，EP16 的域对应同一实例的 DP rank 0–3。异步调度允许主机提交与设备执行重叠，未取消会话依赖，也不意味着所有域没有等待。

正式耗时从第一条实际 HTTP 发送到最后一条 SSE 完成，覆盖该区间全部依赖与准入等待，不含启动/profile、文件准备及冷 reset。TTFT 从发送前、正文序列化开始前计至首个生成 token；E2E 从相同起点至流完成，均排除请求发送前的依赖和准入等待。bench 方法仍适用，本轮并发上限为 C12。

四组结果

部署	全机实际 KV GiB	输入 token 缓存采用率	实际 prefill tokens	全程秒	全程分钟
Non EP4	227.363	82.7933%	50,688,150	1,949.28	32.488
Non EP8	468.826	93.3092%	19,710,102	1,005.92	16.765
Non EP16	562.681	93.3092%	19,710,102	1,199.91	19.998
AFD eager	**515.770**	**93.3092%**	**19,710,102**	**940.08**	**15.668**

全机 KV 为实际独立 tensor storage 之和，包含各 TP DIE 的驻留副本；缓存采用率是采用缓存的输入 tokens / 全部输入 tokens，并非命中请求比例。实际 prefill 来自服务端原生 `request_finished`，逐条与 HTTP usage 匹配。四组均满足 输入 `tokens` = 采用缓存 `tokens` + 实际 `prefill tokens`，没有抢占重算。完整指标和逐域容量保留未舍入值。

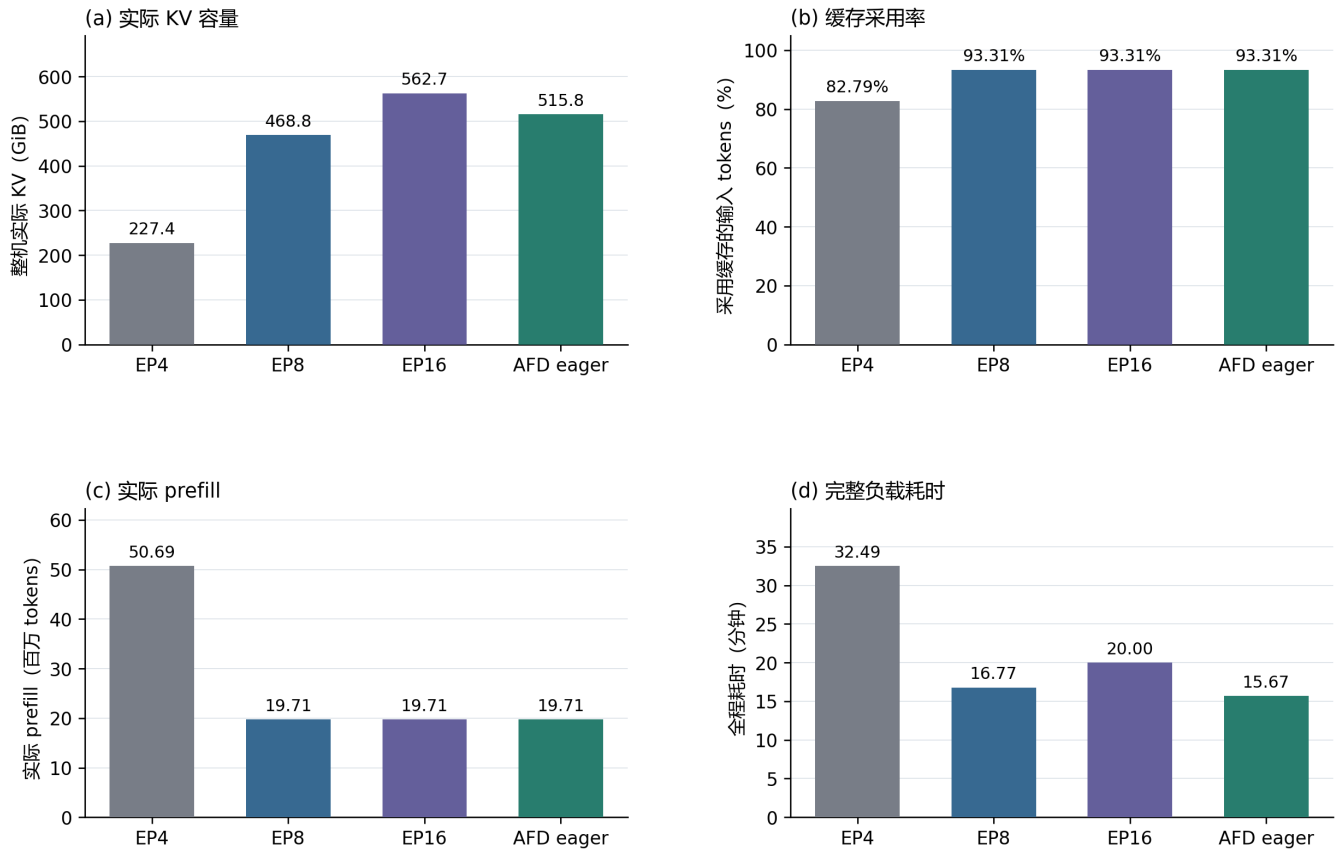


图 1 | 相同输入与资源预算下的四组实测。矢量版、作图数据。

AFD 相对 EP4、EP8、EP16 的时长缩短为 **51.77% / 6.54% / 21.65%**，对应全程加速约 **2.074× / 1.070× / 1.276×**。时长缩短采用 `1−AFD耗时/对照耗时`，没有与吞吐增长百分比混用。

显存与缓存工作量如何影响收益

部署/角色	DIE 数	每 DIE 权重加载占用 GiB	每 DIE 实际 KV GiB	每 DIE profile 后 HBM 已用 GiB
EP4	16	38.4446	14.2089–14.2119	56.9238–57.1914
EP8	16	22.1503	29.2999–29.3044	55.7930–56.0771
EP16	16	14.0032	35.1668–35.1691	53.5762–53.8438
AFD A	12	6.6995	42.9804–42.9819	55.5557–55.8223
AFD F	4	35.9467	无 attention KV 分配记录	53.5928–53.8545

权重为加载日志报告值，源码使用 bytes/2^{30}，本报告按 GiB 记录。权重加载、KV 分配和 HBM 快照属于不同记录阶段，不能直接相减得到精确的工作区占用。F 的未知 profile 分项保留为空，不填成测得的零；完整 64 DIE 的分项与原值见逐 DIE 显存。

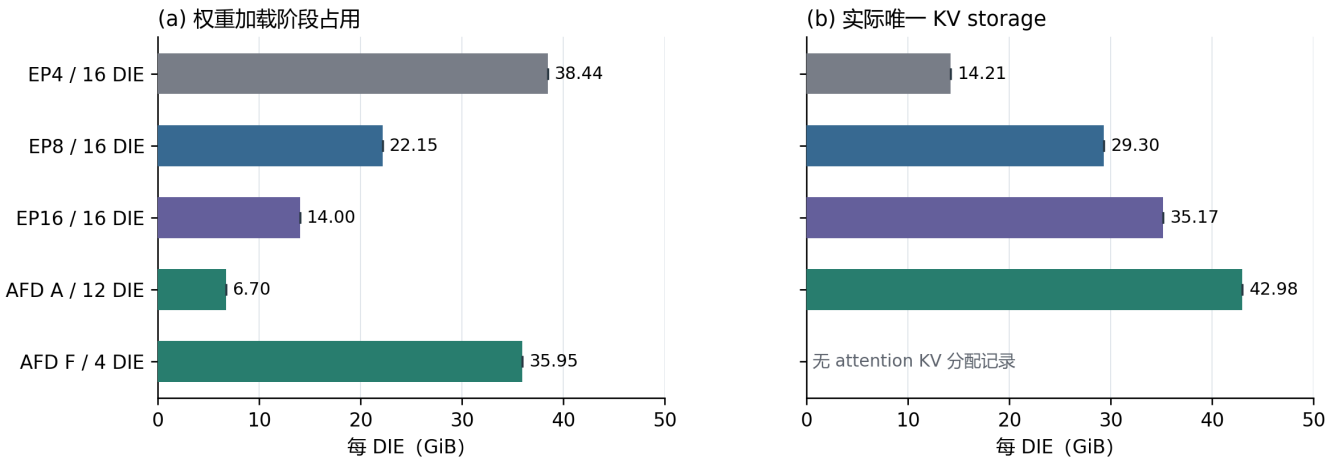


图 2 | 每 DIE 均值，细线表示本组最小至最大范围；两个阶段分开显示。矢量版。

AFD 相对 EP4、EP8 减少专家权重的重复驻留，为 A 侧留下更大的单 DIE KV 空间。在本次实测中，EP4 有 **466 条请求**采用缓存少于 AFD，其余请求相同；总计多做 **30,978,048** 个 prefill tokens，约为 AFD 实际 prefill 的 **157.17%**。容量压力与这项额外工作量相符，但专家布局、通信和组批也随部署变化，不能将全部 51.77% 时长缩短精确归给缓存。

EP8、EP16 则与 AFD 的 **每一条请求**输入及缓存采用均相同，并非仅总命中率碰巧一致。EP16 比 AFD 多 **46.91 GiB** KV，本次没有因此少做 prefill。于是，AFD 在保有对 EP4 缓存工作量优势的同时，没有承担相对 EP16 的额外 prefill。对 EP8、EP16 的收益体现为当前配置完成相同实际 prefill 的系统效率差异；等量 token 仍不等于完全相同的 FLOPs、批形状或执行轨迹。

这也说明容量优势是否兑现取决于工作集。此前 256 会话 / C16 五组实验中，EP16 比 AFD 少做 31,391,744 个 prefill tokens，并且完成更快。本轮不改写旧结论：负载、并发和对子集重建的路由均已变化，无法把收益反转归结为“只调小 C”或单一缓存阈值。两组实验共同显示，AFD 的收益需要结合历史复用压力和实际执行效率判断。

请求延迟与可观察的等待

指标	Non EP4	Non EP8	Non EP16	AFD eager
吞吐，请求/秒	1.911	3.703	3.104	**3.962**
TTFT 均值，秒	6.239	3.171	3.793	**2.936**
TTFT P50，秒	2.722	2.831	3.486	**2.531**
TTFT P95，秒	24.768	6.532	6.676	**6.361**
TTFT P99，秒	39.354	9.552	8.743	**8.611**
E2E 均值，秒	6.240	3.174	3.797	**2.939**
平均在途 HTTP 请求数	11.925	11.754	11.787	11.646

AFD 在这一次试验的均值和所列分位数均更低，C12 下各组平均在途请求均接近上限。不过各组请求共享调度与缓存状态，3,725 条请求不能充当 3,725 次独立试验；尾部的细小差距没有重复运行确认。

原生 metrics 相对各域冷基线的增量给出以下请求平均阶段值：

部署	等待首次调度 WAITING，秒	首次调度至生成结束 RUNNING，秒	客户端 E2E 两段之外，秒
Non EP4	1.9097	3.7930	0.5378
Non EP8	0.1354	2.2086	0.8301
Non EP16	0.1085	2.5803	1.1080
AFD eager	0.0041	2.2039	0.7310

AFD 与 EP8 的平均 RUNNING 接近，AFD 的首次调度前等待更短；EP16 的平均 RUNNING 与客户端残差都更长。这些是定位后续问题的观测，并未证明具体责任组件。RUNNING 包含组批、计算、通信和执行期间等待，残差也包含多种客户端/服务链路开销，均不能直接叫作纯设备计算或单一主机开销。上述请求平均值不能分解有重叠的全程耗时。本轮未新增 profiler，也未据此修改同步逻辑。原生统计与口径保留原始增量与限制。

模拟筛选与实测的一致性

部署	模拟 prefill	实测 prefill	实测减模拟	缓存不同的请求数
Non EP4	45,760,662	50,688,150	+4,927,488	109
Non EP8	19,710,102	19,710,102	0	0
Non EP16	19,710,102	19,710,102	0	0
AFD eager	19,710,102	19,710,102	0	0

AFD、EP8、EP16 的逐请求缓存预测全部复现；EP4 实测 prefill 比预测高 **10.77%**。模拟使用原生异步 checkpoint 调度类，但采用立即回调和各域等步推进，未仿真真实设备、通信、HTTP 和跨域推进时间。自然 profile 的容量也有少量 block 变化，因此不能把 EP4 误差单独归给容量或顺序。模拟支持缓存工作量筛选，其压力区间结果和端到端收益仍需实测。模拟与实测对照保留逐域 N/B、布局一致性及逐请求差异数量。

复核结论与边界

这次比较的负载身份、完整会话、模型/软件、16 DIE 资源、C12、会话依赖、冻结优先级、亲和落点、有效异步调度与原生计数均通过核对；未发现影响本次既定部署比较的执行或配置偏差。结果支持：**在本次 prefix-on、128 完整会话、C12 的 workflow 下，AFD eager 同时优于 EP4、EP8、EP16。** 原始 256 会话结果独立保留，未被替换或合并。

适用边界仍然明确：每组一次、固定顺序，同机排除了跨机器差异，但没有通过反顺序重复排除时间与系统波动；尤其对 EP8 的 6.54% 收益还不能称稳定。MBT、域数、通信与动态组批没有做因素隔离，也未证明各 Non 拓扑已达到最优。此次精度检查沿用既定版本证据，并验证实际加载身份、输出 token 与流完整性，没有新增全面数值精度评测。review.json记录设计审阅、数据证据与限制。

发布前还核对了准备清单：其中几项描述性的 selection、coverage、length distribution 字段继承了母集统计。原始清单保留；公开 128 会话清单依据完整索引与已发布母集的原始行重算，正文、输入哈希、优先级、路由、发压参数和性能记录均未改变。

四次正式回放各完成一次。首次 AFD 在发压前因沿用旧记录用途断言失败，0 条正式请求；仅修正记录断言后，经离线检查并获用户明确批准补跑一次，成功 AFD 使用新 run ID v2。失败记录独立保留。首个模型启动至最后服务清理 **118.61 分钟**，未超过原 135 分钟预算。运行历史、成本审计与证据包身份可追溯。清理时自有模型/回放进程已停止，任务与数据按约定保留；此记录不代表资源当前状态。

公开材料包括 14,900 条数值请求、29,800 条准入/完成事件、64 DIE 显存、15 域容量、冻结索引/路由、实际配置和审计；机器日志、完整环境、模型和 native 二进制不随 Git 发布。所有公开文件与原来源的 SHA256/字段变换见 sources.json。可直接离线复核：

```
python3 scripts/recompute_results.py --result-set 2026-10-14-c12-128
```

报告同时提供 PDF、自包含 HTML与证据索引。本次仓库整理只做文档、图表和离线验证，没有新增设备回放。